

# GBI

## Tutorium 2<sup>5</sup>

Übersetzungen/Kodierungen, Zweierkomplement, Huffman-Codierung  
Jan Zwerschke upezu@student.kit.edu | 13.11.2019



- Wahrheitstabellen beginnen mit fff und “zählen“ dann hoch
- fff, ffw, fww, wff, wfw, wwf, www (wie Binärzahlen)
- $B_1 \equiv B_2$  um zu zeigen, dass zwei Ausdrücke für jede Belegung gleichen Wahrheitswert haben
- $(a \wedge b) \vee b \equiv b$
- $f : \mathbb{N}_0 \times \mathbb{N}_0 \rightarrow \mathbb{N}_0$  Zeige etwas für alle  $n \in \mathbb{N}_0$
- $f(n+1, n+1) = 2f(n, n) + f(n+1, n-1) + f(n-1, n+1)$
- Wie muss Induktionsanfang/voraussetzung lauten?
- IA für  $n = 0$  und  $n = 1$
- IV: Behauptung gelte für ein  $n \in \mathbb{N}_+$

Wir betrachten die Alphabete  $A_{dez} := \mathbb{Z}_{10}$ ,  $A_{bin} := \{0, 1\}$ ,  $A_{oct} := \mathbb{Z}_8$ .

- Was können wir daraus machen?
- $A_{dez}^* \supset \{42, 1337, 999\}$ .
- $A_{bin}^* \supset \{101010, 10100111001, 1111100111\}$ .
- $A_{oct}^* \supset \{52, 2471, 1747\}$ .
- Wir suchen eine Möglichkeit, diese Zahlen zu deuten.
- Aber irgendwie so, dass  $42_{\in A_{dez}} \stackrel{\text{Deutung}}{=} 101010_{\in A_{bin}} \stackrel{\text{Deutung}}{=} 52_{\in A_{oct}}$ .

## $Num_k$

Einer Zeichenkette  $Z_k$  aus Ziffern wird mit  $Num_k$  eine eindeutige Zahl zugeordnet:

$$Num_k(\varepsilon) = 0$$

$$Num_k(wx) = k \cdot Num_k(w) + num_k(x) \text{ mit } w \in Z_k^* \text{ und } x \in Z_k.$$

## $num_k$

Einer einzelnen Ziffer  $x \in Z_k$  aus einem Alphabet von Ziffern  $Z_k$  wird mit  $num_k(x)$  der Wert der Zahl zugewiesen.

- Wichtig:  $Num_k(w) \neq num_k(w)$ !
- Was ist:  $num_{10}(3) = 3$ ,  $num_{10}(7) = 7$ ,  $num_{10}(11) =$  nicht definiert.
- Für Zahlen  $\geq k$ : Benutze  $Num_k$ !

# Beispiel zu Zahlendarstellungen

$$\text{Num}_k(\varepsilon) = 0.$$

$$\text{Num}_k(wx) = k \cdot \text{Num}_k(w) + \text{num}_k(x) \text{ mit } w \in Z_k^* \text{ und } x \in Z_k.$$

Was ist  $\text{Num}_{10}(123)$ ?

$$\begin{aligned} \blacksquare \text{Num}_{10}(123) &= 10 \cdot \text{Num}_{10}(12) + \text{num}_{10}(3) = \\ &10 \cdot (\text{Num}_{10}(1) + \text{num}_{10}(2)) + \text{num}_{10}(3) = \\ &10 \cdot (\text{num}_{10}(1) + 10 \cdot \text{num}_{10}(2)) + \text{num}_{10}(3) = 10 \cdot 10 \cdot 1 + 10 \cdot 2 + 3 = 123. \end{aligned}$$

Yay?

Was ist der dezimale Zahlenwert der Binärzahl 1010? Diesmal Basis

$k = 2$ .

$$\begin{aligned} \blacksquare \text{Num}_2(1010) &= 2 \cdot \text{Num}_2(101) + \text{num}_2(0) = \\ &2 \cdot (2 \cdot \text{Num}_2(10) + \text{num}_2(1) + \text{num}_2(0)) = \\ &2 \cdot (2 \cdot (2 \cdot \text{Num}_2(1) + \text{num}_2(0)) + \text{num}_2(1)) + \text{num}_2(0) = \\ &2 \cdot (2 \cdot (2 \cdot \text{num}_2(1) + \text{num}_2(0)) + \text{num}_2(1)) + \text{num}_2(0) = \\ &2 \cdot (2 \cdot (2 \cdot 1 + 0) + 1) + 0 = 10. \end{aligned}$$

Yay!

$$\text{Num}_k(\varepsilon) = 0.$$

$$\text{Num}_k(wx) = k \cdot \text{Num}_k(w) + \text{num}_k(x) \text{ mit } w \in Z_k^* \text{ und } x \in Z_k.$$

## Übungen zu Zahlendarstellungen

Berechne den numerischen Wert der folgenden Zahlen anderer Zahlensysteme nach dem vorgestellten Schema:

- $\text{Num}_8(345)$ .
- $\text{Num}_2(11001)$ .
- $\text{Num}_2(1000)$ .
- $\text{Num}_4(123)$ .
- $\text{Num}_{16}(4DF)$ . (Zusatz)

Anmerkung: Hexadezimalzahlen sind zur Basis 16 und verwenden als Ziffern (in aufsteigender Reihenfolge):  
1, 2, 3, 4, 5, 6, 7, 8, 9, A, B, C, D, E, F.

## Lösungen:

- $Num_8(345) = 229.$
- $Num_2(11001) = 25.$
- $Num_2(1000) = 8.$
- $Num_4(123) = 27.$
- $Num_{16}(4DF) = 1247.$

# Einfachere Umrechnung von Zahlendarstellungen

Es gilt:

$$2(2(2(2(2 \cdot 1 + 0) + 1) + 0) + 1) + 0 = 2^5 \cdot 1 + 2^4 \cdot 0 + 2^3 \cdot 1 + 2^2 \cdot 0 + 2^1 \cdot 1 + 2^0 \cdot 0.$$

Daher, einfachere Rechenweise:

$$\text{Num}_k(w) = k^0 \cdot w(0) + k^1 \cdot w(1) + k^2 \cdot w(2) + \dots$$

Was sind folgende Zahlen in Dezimal im Kopf gerechnet?

- $\text{Num}_2(10101) = 21.$
- $\text{Num}_2(11101) = 29.$
- $\text{Num}_2(111111111) = 1023.$



# Einfachere Umrechnung von Zahlendarstellungen

$$\text{Num}_k(w) = k^0 \cdot w(0) + k^1 \cdot w(1) + k^2 \cdot w(2) + \dots$$

Was sind folgende Zahlen in Dezimal im Kopf gerechnet?

- $\text{Num}_{16}(A1) = 161.$
- $\text{Num}_{16}(BC) = 188.$
- $\text{Num}_{16}(14) = 20.$

- Ist Num injektiv?  $Num_2(01) = Num_2(1)$
- Ist Num surjektiv? Ja

## *div* Funktion

Die Funktion *div* dividiert ganzzahlig. (Schneidet also den Rest ab).

## *mod* Funktion

Die Modulo Funktion *mod* gibt den Rest einer ganzzahligen Division zurück.

■  $22 \text{ div } 8 = 2 \left( \frac{22}{8} = 2,75 \right).$

■  $22 \text{ mod } 8 = 6.$

Fülle die Tabelle aus:

x	0	1	2	3	4	5	6	7	8	9	10	11	12
$x \text{ div } 4$	0	0	0	0	1	1	1	1	2	2	2	2	3
$x \text{ mod } 4$	0	1	2	3	0	1	2	3	0	1	2	3	0

$11101_2$  ist also  $29_{10}$ . Was ist  $29_{10}$  in binär?

## $k$ -äre Darstellung

Die Repräsentation einer Zahl  $n$  zur Basis  $k$  lässt sich wie folgt ermitteln:

$$\mathbf{Repr}_k(n) = \begin{cases} \mathbf{repr}_k(n) & \text{falls } n < k \\ \mathbf{Repr}_k(n \text{ div } k) \cdot \mathbf{repr}_k(n \bmod k) & \text{falls } n \geq k \end{cases}$$

Achtung! Das  $\cdot$  Symbol steht für Konkatenation, nicht für Multiplikation!

$$\text{Repr}_k(n) = \begin{cases} \text{repr}_k(n) & \text{falls } n < k \\ \text{Repr}_k(n \text{ div } k) \cdot \text{repr}_k(n \bmod k) & \text{falls } n \geq k \end{cases}$$

Zum Beispiel:

$$\begin{aligned} \text{Repr}_2(29) &= \text{Repr}_2(29 \text{ div } 2) \cdot \text{repr}_2(29 \bmod 2) \\ &= \text{Repr}_2(14) \cdot \text{repr}_2(1) \\ &= \text{Repr}_2(14 \text{ div } 2) \cdot \text{repr}_2(14 \bmod 2) \cdot 1 \\ &= \text{Repr}_2(7) \cdot \text{repr}_2(0) \cdot 1 \\ &= \text{Repr}_2(7 \text{ div } 2) \cdot \text{repr}_2(7 \bmod 2) \cdot 01 \\ &= \text{Repr}_2(3) \cdot \text{repr}(1) \cdot 01 \\ &= \text{Repr}_2(3 \text{ div } 2) \cdot \text{repr}(3 \bmod 2) \cdot 101 \\ &= \text{Repr}_2(1) \cdot \text{repr}(1) \cdot 101 \\ &= 11101 \end{aligned}$$

$$\text{Repr}_k(n) = \begin{cases} \text{repr}_k(n) & \text{falls } n < k \\ \text{Repr}_k(n \text{ div } k) \cdot \text{repr}_k(n \bmod k) & \text{falls } n \geq k \end{cases}$$

Beispiel mit Hexadezimalzahlen:

$$\begin{aligned} \text{Repr}_{16}(29) &= \text{Repr}_{16}(29 \text{ div } 16) \cdot \text{repr}_{16}(29 \bmod 16) \\ &= \text{Repr}_{16}(1) \cdot \text{repr}_{16}(13) \\ &= 1 \cdot D = 1D \end{aligned}$$

$$\text{Repr}_k(n) = \begin{cases} \text{repr}_k(n) & \text{falls } n < k \\ \text{Repr}_k(n \text{ div } k) \cdot \text{repr}_k(n \bmod k) & \text{falls } n \geq k \end{cases}$$

## Übung zu $\text{Repr}_k$

Berechne die Repräsentationen folgender Zahlen in gegebenen Zahlensystemen:

- $\text{Repr}_2(13)$ .
- $\text{Repr}_4(15)$ .
- $\text{Repr}_{16}(268)$ .

- $\text{Repr}_2(13) = 1101$ .
- $\text{Repr}_4(15) = 33$ .
- $\text{Repr}_{16}(268) = 10C$ .

## $\text{bin}_\ell$

Die Funktion  $\text{bin}_\ell: \mathbb{Z}_{2^\ell} \rightarrow \{0, 1\}^\ell$  bringt eine gegebene Binärzahl auf eine feste Länge, indem sie mit Nullen vorne aufgefüllt wird. Formell wird sie definiert als:

$$\text{bin}_\ell(n) = 0^{\ell - |\text{Repr}_2(n)|} \text{Repr}_2(n)$$

Beispiel:

- $\text{bin}_8(3) = 0^{8 - |\text{Repr}_2(3)|} \text{Repr}_2(3) = 0^{8 - |11|} \cdot 11 = 0^{8-2} \cdot 11 = 0^6 \cdot 11 = 00000011.$
- $\text{bin}_{16}(3) = 0000000000000011.$



Was ist mit negativen Zahlen?

- Idee: Verwende den ersten Buchstaben, um zu speichern, ob die Zahl positiv oder negativ ist.
- Beispiel:  $5 = 0101_{zkpl}$ ,  $-5 = 1011_{zkpl}$ .

## Zweierkomplement Darstellung

Die Zweierkomplementdarstellung einer Zahl  $x$  mit der Länge  $\ell$  ist wie folgt definiert:

$$\mathbf{Zkpl}_{\ell}(x) = \begin{cases} 0\mathbf{bin}_{\ell-1}(x) & \text{falls } x \geq 0 \\ 1\mathbf{bin}_{\ell-1}(2^{\ell-1} + x) & \text{falls } x < 0 \end{cases}$$

- Wieso  $\ell - 1$ ?

# Aufgaben zu Zweierkomplement-Darstellung

$$\mathbf{Zkpl}_\ell(x) = \begin{cases} 0\mathbf{bin}_{\ell-1}(x) & \text{falls } x \geq 0 \\ 1\mathbf{bin}_{\ell-1}(2^{\ell-1} + x) & \text{falls } x < 0 \end{cases}$$

Was sind folgende Zahlen in Zweierkomplement-Darstellung?

- $\mathbf{Zkpl}_4(3) = 0011$ .
- $\mathbf{Zkpl}_4(7) = 0111$ .
- $\mathbf{Zkpl}_4(-5) = 1011$ .
- $\mathbf{Zkpl}_8(13) = 00001101$ .
- $\mathbf{Zkpl}_8(-34) = 11011110$ .
- $\mathbf{Zkpl}_8(-9) = 11110111$ .

## Definition der Semantikabbildung

Sei  $Sem$  die Menge der Bedeutungen. Ferner seien  $A$  und  $B$  Alphabete und  $L_A \subseteq A^*$  und  $L_B \subseteq B^*$ .

Weiter sei  $sem_A : L_A \rightarrow Sem$  und  $sem_B : L_B \rightarrow Sem$

Dann heißt  $f : L_A \rightarrow L_B$  Übersetzung, wenn gilt: für jedes  $w \in L_A$  gilt  $sem_A(w) = sem_B(f(w))$ .

- Bedeutungserhaltende Abbildungen von Wörtern auf Wörter

## Beispiel

Betrachte  $Trans_{2,16} : \mathbb{Z}_{16}^* \rightarrow \mathbb{Z}_2^*$  mit  $Trans_{2,16}(w) = Repr_2(Num_{16}(w))$

- $Trans_{2,16}(A3) = Repr_2(Num_{16}(A3)) = Repr_2(163) = 10100011$

- Lesbarkeit (vergleiche  $DF_{16}$  mit  $11011111_2$ )
- Verschlüsselung
- Kompression (Informationen platzsparend aufschreiben)
- Kontextabhängige Semantiken (Deutsch  $\rightarrow$  Englisch)
- Fehlererkennung

## Definitionen

- Codewort  $f(w)$  einer Codierung  $f : L_A \rightarrow L_B$
- Code:  $\{f(w) | w \in L_A\} = f(L_A)$
- Codierung: **Injektive** Übersetzung
  - Ich komme immer eindeutig von einem Codewort  $f(w)$  zu  $w$  zurück

## Bemerkung

- Was ist, wenn  $L_A$  unendlich ist (man kann nicht alle Möglichkeiten aufzählen)
- Auswege: Homomorphismen, Block-Codierungen

## Definition von Homomorphismen

Seien  $A, B$  Alphabete. Dann ist  $h : A^* \rightarrow B^*$  ein Homomorphismus, falls für alle  $w_1, w_2 \in A^*$  gilt:

$$h(w_1 w_2) = h(w_1)h(w_2)$$

- Ein Homomorphismus ist Abbildung, die mit Konkatenation verträglich ist
- Homomorphismus ist  $\varepsilon$ -frei, wenn für jedes  $x \in A : h(x) \neq \varepsilon$
- Homomorphismen lassen das leere Wort unverändert, also  $h(\varepsilon) = \varepsilon$

Sei  $h$  ein Homomorphismus.

## Übung zu Homomorphismen

1.  $h(a) = 001$  und  $h(b) = 1101$ . Was ist dann  $h(bba)$ ?

→  $h(bba) = h(b)h(b)h(a) = 1101 \cdot 1101 \cdot 001 = 11011101001$

2. Sei  $h(a) = 01$ ,  $h(b) = 11$  und  $h(c) = \varepsilon$ . Nun sei  $h(w) = 011101$ .  
Was war  $w$ ?

→  $aba$  oder  $cabccac$ , ... Allgemein:

$$w \in \{c\}^* \cdot \{a\} \cdot \{c\}^* \cdot \{b\} \cdot \{c\}^* \cdot \{a\} \cdot \{c\}^*$$

$\varepsilon$ -Freiheit hat also die Eindeutigkeit zerstört!

3. Kann  $h$  aus 2 eine Codierung sein?

→ Nein, da nicht injektiv!

4. Warum will man  $\varepsilon$ -freie Homomorphismen?

→ Information geht sonst verloren!

5. Was heißt hier "Information geht verloren"?

→ Es gibt  $w_1 \neq w_2$  mit  $h(w_1) = h(w_2)$

- Information kann auch anders “verloren” gehen

→ z.B.  $h(a) = 0$ ,  $h(b) = 1$ ,  $h(c) = 10$  – Wie das?

## Präfixfreiheit

Gegeben ist ein Homomorphismus  $h : A^* \rightarrow B^*$ .

Wenn für keine zwei verschiedenen  $x_1, x_2 \in A$  gilt, dass  $h(x_1)$  Präfix von  $h(x_2)$  ist, dann ist  $h$  präfixfrei.

## Satz

Präfixfreie Codes sind injektiv.

## Beispiele

- $h(a) = 01$  und  $h(b) = 1101$  ist präfixfrei
- $g(a) = 01$  und  $g(b) = 011$  ist nicht präfixfrei



- Komprimiert eine Zeichenkette
- Kodiert häufiger vorkommende Zeichen zu kürzeren Codewörter als Zeichen die seltener vorkommen.
- Vorgehensweise:
  1. Zähle Häufigkeiten aller Zeichen der Zeichenkette
  2. Schreibe alle vorkommenden Zeichen und ihre Häufigkeiten nebeneinander
  3. Wiederhole, bis der Baum fertig ist:
    - Verbinde die zwei Zeichen mit niedrigsten Häufigkeiten zu neuem Knoten über diesen
    - Dieser hat als Zahl die aufsummierte Häufigkeiten
  4. Danach: Alle linken Kanten werden mit 0 kodiert, alle rechten Kanten mit 1

Das Ergebnis ist eine Zeichenkette aus  $\{0, 1\}$ , die kürzer ist als die ursprüngliche Zeichenkette in binär.

Gegeben

- $w \in A^*$   
 $w = \text{afebfecaaffdeddccefbff}$
- Anzahl der Vorkommen aller Zeichen in  $w$  ( $N_x(w)$ )

**Häufigkeiten:**


x	a	b	c	d	e	f
$N_x(w)$	2	2	3	3	5	7

Zwei Phasen zur Bestimmung eines

**Huffman-Codes**

1. Konstruieren eines “Baumes”

- Blätter entsprechen den Zeichen
- Kanten mit 0 und 1 beschriften



**Häufigkeiten:**

## Übung

Sei  $A = \{a, b, c, d, e, f, g, h\}$

- Codiere das Wort badcf ehg mit Hilfe der Huffman-Codierung

→ Mögliche Lösung: 001 100 010 011 101 000 111 110

- Wie lauten die Codewörter, wenn für das Wort  $w$  gilt:

$$N_a(w) = 1, N_b(w) = 2, N_c(w) = 2, N_d(w) = 8, N_e(w) = 16, N_f(w) = 32, N_g(w) = 64, N_h(w) = 128$$

Mögliche Lösung:

x	a	b	c	d	e	f	g	h
h(x)	0000000	0000001	000001	00001	0001	001	01	1

- Wie lang wäre das zweite Wort ( $abbcccc\ d^8 \dots g^{64} h^{128}$ ) mit dem ersten Code codiert?
- 741 Symbole. Also dreimal so lang wie das Original.
- Wie lang wäre das zweite Wort mit dem zweiten Code codiert?
- 501 Symbole. Also nur zweimal so lang wie das Original.
- Was fällt euch auf?

Sei  $h : A^* \rightarrow \mathbb{Z}_2$  eine Huffman-Codierung

- $h$  ist ein  $\varepsilon$ -freier Homomorphismus **Wahr!**
- Häufigere Symbole werden mit langen Worten codiert, seltene mit kürzeren **Falsch!**
- Die Kompression ist am stärksten, wenn die Häufigkeiten aller Zeichen ungefähr gleich sind. **Falsch!**
- $h$  ist präfixfrei **Wahr!**
- Es kann noch kürzere Codierungen geben **Falsch!**

## Eigenschaften

Sei  $A$  ein Alphabet und  $w \in A$ . Dann gilt für die Huffman-Codierung  $h$ :

- $h : A^* \rightarrow \mathbb{Z}_2$
- $h$  ist  $\varepsilon$ -freier Homomorphismus
- $h$  ist präfixfreier Homomorphismus
- Häufigere Symbole werden mit kurzen Worten codiert, seltene mit längeren
- Produziert kürzestmögliche Codierungen

- Wir betrachten nicht mehr einzelne Symbole, sondern Blöcke von fester Länge  $b > 1$
- Blätter des Huffman-Baums sind jetzt *Wörter der Länge  $b$*

Beispiel an der Tafel: Codierung von  
 $aab \cdot deg \cdot deg \cdot aab \cdot ole \cdot aab \cdot deg \cdot aab$ .

- Alphabet  $A = \{a, b, c, d\}$
  - Text über  $A$ , der nur aus Teilwörtern der Länge 10 zusammengesetzt ist, in denen jeweils immer nur ein Symbol vorkommt
  - Angenommen  $a^{10}, \dots, d^{10}$  kommen alle gleich häufig vor. Wie lang ist dann die Huffman-Codierung?
- Ein Fünftel, weil jeder Zehnerblock durch zwei Bits codiert wird

Sei  $h : A^* \rightarrow \mathbb{Z}_2$  eine Huffman-Codierung

- $h$  ist ein  $\varepsilon$ -freier Homomorphismus **Wahr!**
- Häufigere Symbole werden mit langen Worten codiert, seltene mit kürzeren **Falsch!**
- Die Kompression ist am stärksten, wenn die Häufigkeiten aller Zeichen ungefähr gleich sind. **Falsch!**
- $h$  ist präfixfrei **Wahr!**
- Es kann noch kürzere Codierungen geben **Falsch!**





*That's all Folks!*