


Grundbegriffe der Informatik

Tutorium 38

Übersetzungen/Kodierungen, Zweierkomplement, Huffman-Codierung
Patrick Fetzer, uxkln@student.kit.edu | 15.11.2018



- Wahrheitstabellen beginnen mit fff und “zählen” dann hoch
- fff, ffw, fww, wff, wfw, wwf, www (wie Binärzahlen)
- $B_1 \equiv B_2$ um zu zeigen, dass zwei Ausdrücke für jede Belegung gleichen Wahrheitswert haben
- $(a \wedge b) \vee b \equiv b$
- $f : \mathbb{N}_0 \times \mathbb{N}_0 \rightarrow \mathbb{N}_0$ Zeige etwas für alle $n \in \mathbb{N}_0$
- $f(n+1, n+1) = 2f(n, n) + f(n+1, n-1) + f(n-1, n+1)$
- Wie muss Induktionsanfang/voraussetzung lauten?
- IA für $n = 0$ und $n = 1$
- IV: Behauptung gelte für ein $n \in \mathbb{N}_+$

- Was können wir daraus machen?
- $A_{dez}^* \supset \{42, 1337, 999\}$.
- $A_{bin}^* \supset \{101010, 10100111001, 1111100111\}$.
- $A_{oct}^* \supset \{52, 2471, 1747\}$.
- Wir suchen eine Möglichkeit, diese Zahlen zu deuten.
- Aber irgendwie so, dass $42_{\in A_{dez}} \stackrel{\text{Deutung}}{=} 101010_{\in A_{bin}} \stackrel{\text{Deutung}}{=} 52_{\in A_{oct}}$.

Einer Zeichenkette Z_k aus Ziffern wird mit Num_k eine eindeutige Zahl zugeordnet:

$$Num_k(\varepsilon) = 0$$

$$Num_k(wx) = k \cdot Num_k(w) + num_k(x) \text{ mit } w \in Z_k^* \text{ und } x \in Z_k.$$

 num_k

Einer einzelnen Ziffer $x \in Z_k$ aus einem Alphabet von Ziffern Z_k wird mit $num_k(x)$ der Wert der Zahl zugewiesen.

- Wichtig: $Num_k(w) \neq num_k(w)$!
- Was ist: $num_{10}(3) = 3$, $num_{10}(7) = 7$, $num_{10}(11) =$ nicht definiert.
- Für Zahlen $> k$: Benutze Num_k !

$$Num_k(\varepsilon) = 0.$$

$$Num_k(wx) = k \cdot Num_k(w) + num_k(x) \text{ mit } w \in Z_k^* \text{ und } x \in Z_k.$$

Was ist $Num_{10}(123)$?

- $Num_{10}(123) = 10 \cdot Num_{10}(12) + num_{10}(3) =$
 $10 \cdot (Num_{10}(1) + num_{10}(2)) + num_{10}(3) =$
 $10 \cdot (num_{10}(1) + 10 \cdot num_{10}(2)) + num_{10}(3) = 10 \cdot 10 \cdot 1 + 10 \cdot 2 + 3 = 123.$

Yay?

Was ist der dezimale Zahlenwert der Binärzahl 1010? Diesmal Basis

$k = 2.$

- $$\begin{aligned} \text{Num}_2(1010) &= 2 \cdot \text{Num}_2(101) + \text{num}_2(0) = \\ &2 \cdot (2 \cdot \text{Num}_2(10) + \text{num}_2(1) + \text{num}_2(0)) = \\ &2 \cdot (2 \cdot (2 \cdot \text{Num}_2(1) + \text{num}_2(0)) + \text{num}_2(1)) + \text{num}_2(0) = \\ &2 \cdot (2 \cdot (2 \cdot \text{num}_2(1) + \text{num}_2(0)) + \text{num}_2(1)) + \text{num}_2(0) = \\ &2 \cdot (2 \cdot (2 \cdot 1 + 0) + 1) + 0 = 10. \end{aligned}$$

Yay!

$$Num_k(\varepsilon) = 0.$$

$$Num_k(wx) = k \cdot Num_k(w) + num_k(x) \text{ mit } w \in Z_k^* \text{ und } x \in Z_k.$$

Übungen zu Zahlendarstellungen

Berechne den numerischen Wert der folgenden Zahlen anderer Zahlensysteme nach dem vorgestellten Schema:

- $Num_8(345)$.
- $Num_2(11001)$.
- $Num_2(1000)$.
- $Num_4(123)$.
- $Num_{16}(4DF)$. (Zusatz)

Anmerkung: Hexadezimalzahlen sind zur Basis 16 und verwenden als Ziffern (in aufsteigender Reihenfolge):
1, 2, 3, 4, 5, 6, 7, 8, 9, A, B, C, D, E, F.

Lösungen:

- $Num_8(345) = 229$.
- $Num_2(11001) = 25$.
- $Num_2(1000) = 8$.
- $Num_4(123) = 27$.
- $Num_{16}(4DF) = 1247$.

- Ist Num injektiv? $Num_2(01) = Num_2(1)$
- Ist Num surjektiv? Ja

11101_2 ist also 29_{10} . Was ist 29_{10} in binär?

k -äre Darstellung

Die Repräsentation einer Zahl n zur Basis k lässt sich wie folgt ermitteln:

$$\mathbf{Repr}_k(n) = \begin{cases} \mathbf{repr}_k(n) & \text{falls } n < k \\ \mathbf{Repr}_k(n \text{ div } k) \cdot \mathbf{repr}_k(n \bmod k) & \text{falls } n \geq k \end{cases}$$

Achtung! Das \cdot Symbol steht für Konkatination, nicht für Multiplikation!

$$\mathbf{Repr}_k(n) = \begin{cases} \mathbf{repr}_k(n) & \text{falls } n < k \\ \mathbf{Repr}_k(n \text{ div } k) \cdot \mathbf{repr}_k(n \bmod k) & \text{falls } n \geq k \end{cases}$$

Übung zu Repr_k

Berechne die Repräsentationen folgender Zahlen in gegebenen Zahlensystemen:

- $\text{Repr}_2(13)$.
 - $\text{Repr}_4(15)$.
 - $\text{Repr}_{16}(268)$.
-
- $\text{Repr}_2(13) = 1101$.
 - $\text{Repr}_4(15) = 33$.
 - $\text{Repr}_{16}(268) = 10C$.

$$\mathbf{Zkpl}_\ell(x) = \begin{cases} 0\mathbf{bin}_{\ell-1}(x) & \text{falls } x \geq 0 \\ 1\mathbf{bin}_{\ell-1}(2^{\ell-1} + x) & \text{falls } x < 0 \end{cases}$$

Was sind folgende Zahlen in Zweierkomplement-Darstellung?

- $\mathbf{Zkpl}_4(3) = 0011.$
- $\mathbf{Zkpl}_4(7) = 0111.$
- $\mathbf{Zkpl}_4(-5) = 1011.$
- $\mathbf{Zkpl}_8(13) = 00001101.$
- $\mathbf{Zkpl}_8(-34) = 11011110.$
- $\mathbf{Zkpl}_8(-9) = 11110111.$

Definition der Semantikabbildung

Sei Sem die Menge der Bedeutungen. Ferner seien A und B Alphabete und $L_A \subset A^*$ und $L_B \subset B^*$.

Weiter sei $\text{sem}_A : L_A \rightarrow \text{Sem}$ und $\text{sem}_B : L_B \rightarrow \text{Sem}$

Dann heißt $f : L_A \rightarrow L_B$ Übersetzung , wenn gilt: für jedes $w \in L_A$ gilt $sem_A(w) = sem_B(f(w))$.

- Bedeutungserhaltende Abbildungen von Wörtern auf Wörter

Beispiel

Betrachte $Trans_{2,16} : \mathbb{Z}_{16}^* \rightarrow \mathbb{Z}_2^*$ mit $Trans_{2,16}(w) = Repr_2(Num_{16}(w))$

- $Trans_{2,16}(A3) = Repr_2(Num_{16}(A3)) = Repr_2(163) = 10100011$

Sei h ein Homomorphismus.

Übung zu Homomorphismen

1. $h(a) = 001$ und $h(b) = 1101$. Was ist dann $h(bba)$?

→ $h(bba) = h(b)h(b)h(a) = 1101 \cdot 1101 \cdot 001 = 11011101001$

2. Sei $h(a) = 01$, $h(b) = 11$ und $h(c) = \varepsilon$. Nun sei $h(w) = 011101$.
Was war w ?

→ aba oder $cabccac$, ... Allgemein:

$$w \in \{c\}^* \cdot \{a\} \cdot \{c\}^* \cdot \{b\} \cdot \{c\}^* \cdot \{a\} \cdot \{c\}^*$$

ε -Freiheit hat also die Eindeutigkeit zerstört!

3. Kann h aus 2 eine Codierung sein?

→ Nein, da nicht injektiv!

4. Warum will man ε -freie Homomorphismen?

→ Information geht sonst verloren!

5. Was heißt hier "Information geht verloren"?

→ Es gibt $w_1 \neq w_2$ mit $h(w_1) = h(w_2)$

Huffman-Codierung

Gegeben

- $w \in A^*$
 $\mathbf{w} = \text{afebfecaffdeddccefbfeff}$
- Anzahl der Vorkommen aller Zeichen in w ($N_x(w)$)

Häufigkeiten:


x	a	b	c	d	e	f
$N_x(w)$	2	2	3	3	5	7

Zwei Phasen zur Bestimmung eines

Huffman-Codes

1. Konstruieren eines “Baumes”

- Blätter entsprechen den Zeichen
- Kanten mit 0 und 1 beschriftet



Häufigkeiten:

Hinweise

○

Übung

Sei $A = \{a, b, c, d, e, f, g, h\}$

- Codiere das Wort `badcf ehg` mit Hilfe der Huffman-Codierung

→ Mögliche Lösung: `001 100 010 011 101 000 111 110`

- Wie lauten die Codewörter, wenn für das Wort w gilt:

$$N_a(w) = 1, N_b(w) = 2, N_c(w) = 2, N_d(w) = 8, N_e(w) = 16, N_f(w) = 32, N_g(w) = 64, N_h(w) = 128$$

Mögliche Lösung:

x	a	b	c	d	e	f	g	h
h(x)	0000000	0000001	000001	00001	0001	001	01	1

- Wie lang wäre das zweite Wort ($abbcccc\ d^8 \dots g^{64} h^{128}$) mit dem ersten Code codiert?

→ 741 Symbole. Also dreimal so lang wie das Original.

- Wie lang wäre das zweite Wort mit dem zweiten Code codiert?

→ 501 Symbole. Also nur zweimal so lang wie das Original.

- Was fällt euch auf?

Sei $h : A^* \rightarrow \mathbb{Z}_2$ eine Huffman-Codierung

- h ist ein ε -freier Homomorphismus **Wahr!**
- Häufigere Symbole werden mit langen Worten codiert, seltene mit kürzeren **Falsch!**
- Die Kompression ist am stärksten, wenn die Häufigkeiten aller Zeichen ungefähr gleich sind. **Falsch!**
- h ist präfixfrei **Wahr!**
- Es kann noch kürzere Codierungen geben **Falsch!**

- Wir betrachten nicht mehr einzelne Symbole, sondern Blöcke von fester Länge $b > 1$
- Blätter des Huffman-Baums sind jetzt *Wörter der Länge b*

Beispiel an der Tafel: Codierung von

aab · deg · deg · aab · ole · aab · deg · aab.

- Alphabet $A = \{a, b, c, d\}$
 - Text über A , der nur aus Teilwörtern der Länge 10 zusammengesetzt ist, in denen jeweils immer nur ein Symbol vorkommt
 - Angenommen a^{10}, \dots, d^{10} kommen alle gleich häufig vor. Wie lang ist dann die Huffman-Codierung?
- Ein Fünftel, weil jeder Zehnerblock durch zwei Bits codiert wird

Sei $h : A^* \rightarrow \mathbb{Z}_2$ eine Huffman-Codierung

- h ist ein ε -freier Homomorphismus **Wahr!**
- Häufigere Symbole werden mit langen Worten codiert, seltene mit kürzeren **Falsch!**
- Die Kompression ist am stärksten, wenn die Häufigkeiten aller Zeichen ungefähr gleich sind. **Falsch!**
- h ist präfixfrei **Wahr!**
- Es kann noch kürzere Codierungen geben **Falsch!**



That's all Folks!